RELATÓRIO TÉCNICO E AUDITORIA DO ESTUDO

# Reconhecimento global de entidades e pipeline clínico end-to-end

Análise integrada do PRD, das 13 issues, das decisões arquiteturais e dos resultados de desenvolvimento e avaliação externa.

**210**
testes automatizados aprovados

**63**
documentos na avaliação externa provisória

**0,1123**
melhor macro-F1 relacional externo end-to-end

**CONCLUSÃO DE ALTO NÍVEL**

A implementação de engenharia está funcional, testada e produz o fluxo completo de texto bruto até Knowledge Graph. A conclusão científica final, porém, permanece provisória porque o teste externo não cumpriu a regra de parada pré-registrada e a classe `CAUSES` ficou abaixo do suporte mínimo.

Projeto MC896 · pacote `project2_from_project1`
Data da análise: 19 de outubro de 2026 · Fuso: America/Bahia
Escopo: PRD `.scratch/global-entity-recognition/spec.md`, issues 01–13, ADRs, documentação de resultados e artefatos locais.

# 1. Sumário executivo

**O estudo alcançou seu objetivo de engenharia:** existe um pipeline supervisionado, auditável e reproduzível que parte de texto clínico bruto, reconhece entidades, gera candidatos, classifica relações e produz um grafo versionado. O melhor braço observado foi **semi-Markov CRF + k-NN**. O desempenho absoluto, entretanto, ainda é baixo para uso clínico ou produção.

| 0,2415 | 0,1123 | 0,6053 | 95,9% |
|---|---|---|---|
| macro-F1 externo de entidades — CRF | macro-F1 externo de relações — CRF + k-NN | teto relacional gold + k-NN | FNs relacionais herdados do NER no melhor braço |

### Principais acertos

- **Separação correta entre gold e previsão:** entidades previstas, candidatos sem rótulo e grafo têm contratos próprios, reduzindo leakage e confusão entre resposta e inferência.
- **Comparação fatorial justa:** dicionário e CRF são combinados com regras e k-NN sob o mesmo contrato; o teto com entidades gold é separado dos braços end-to-end.
- **Rastreabilidade forte:** manifests, hashes, versões, partições e proveniência permitem auditar a execução; os 18 arquivos do pacote externo conferem com o manifesto.
- **Resultados negativos preservados:** o CRF não convergiu no limite de 250 iterações, mas foi avaliado sem fallback, conforme o desenho científico.
- **Cobertura de testes:** a suíte completa executada nesta auditoria terminou com 210 testes aprovados.

### Principais problemas

- **Gargalo no reconhecimento de entidades:** entre 93,9% e 97,3% dos falsos negativos relacionais externos dos braços end-to-end decorrem de endpoint ausente ou com borda/tipo errado.
- **Baixa generalização:** no CRF externo, a revocação de superfícies não vistas foi 0,066; menções longas (11–40 tokens) tiveram F1 de apenas 0,0166.
- `Condition` **continua quase ausente:** F1 externo de 0,0486 no CRF, limitando `HAS_CONDITION`.
- **Validação externa incompleta:** há 63 documentos elegíveis e somente 9 relações `CAUSES`; o plano exigia continuar até 20 por classe ou 100 documentos.
- **Dívida de governança:** as issues 01, 06, 07 e 08 ainda constam como “ready-for-agent”, embora testes, código e issues posteriores indiquem implementação; isso enfraquece a trilha de conclusão.

> **PARECER**
>
> O sistema está pronto para pesquisa exploratória e iteração metodológica. Não está pronto para alegações clínicas, implantação operacional ou conclusão externa definitiva. A prioridade deve ser melhorar o NER e completar corretamente o conjunto externo antes de ampliar o esquema semântico.

## 2. Objetivo e desenho do estudo

O PRD parte de uma limitação central: o pipeline anterior classificava relações usando entidades gold. Assim, bons resultados relacionais não demonstravam capacidade de operar sobre texto bruto. O novo desenho procura medir a cadeia inteira e tornar visível a propagação de erros.

### Fluxo implementado

| Etapa | Entrada | Saída principal | Critério científico |
|---|---|---|---|
| 1. Preparação | Corpus lossless | Projeção gold plana | Fonte original preservada; conflitos adjudicados |
| 2. Entidades | Texto bruto | `EntityPrediction` | Offsets e tipo exatos |
| 3. Candidatos | Entidades previstas | `RelationCandidate` | Sem rótulo gold e sem correção posterior |
| 4. Relações | Candidatos previstos | Rótulo ou `NO_RELATION` | Mesmo classificador entre reconhecedores |
| 5. Grafo | Entidades e relações previstas | JSONL v2 em duas camadas | Menção antes de conceito; proveniência preservada |

### Braços comparados

**RECONHECIMENTO DE ENTIDADES**

**Dicionário canônico:** aprende apenas superfícies do treino, usa tipo majoritário e se abstém em empates.

**Semi-Markov CRF:** modelo linear segmental, features esparsas, inferência global, L-BFGS full-batch e L2 selecionado por validação aninhada.

**CLASSIFICAÇÃO DE RELAÇÕES**

**Regras canônicas:** baseline determinístico ajustado no treino.

**k-NN de n-gramas:** unigramas e `k=1`, selecionados previamente. O mesmo modelo do fold recebe candidatos do dicionário e do CRF.

### Boas escolhas metodológicas

- Folds agrupados por documento e seleção de L2 somente em folds internos.
- Vocabulários e dicionários aprendidos apenas no treino.
- Teste MCRC previamente consumido excluído da nova conclusão principal.
- Métrica primária estrita, sem substituir erros de borda por métricas lenientes.
- Falha numérica não finita interrompe somente o braço afetado; não há troca silenciosa de algoritmo.
- Grafo conceitual tratado como avaliação secundária, preservando a camada de menção.

**MUDANÇA RELEVANTE EM RELAÇÃO AO PRD**

O PRD previa dois revisores humanos independentes para a projeção gold plana. Por inviabilidade operacional, a issue 02 adotou três execuções independentes do mesmo modelo de linguagem. A concordância de 98,7% mede consistência do protocolo, mas não substitui concordância entre anotadores humanos e pode compartilhar vieses sistemáticos.

## 3. Auditoria das issues

A tabela cruza o estado registrado nas issues com a evidência encontrada em código, testes, documentação e artefatos. "Funcional" significa que a capacidade está coberta por implementação/testes; não significa que o status administrativo esteja correto.

| Issue | Entrega | Status registrado | Avaliação |
|---|---|---|---|
| 01 | Contratos supervisionados versionados | ready-for-agent | **Funcional, status desatualizado.** Contratos e testes existem; é dependência já consumida pelas issues posteriores. |
| 02 | Projeção gold plana adjudicada | done | **Concluída com desvio.** 3.063 menções; adjudicação por modelos, não por humanos. |
| 03 | Entidades por dicionário | done | **Concluída.** Treino por fold, abstenção em empate, maior correspondência e avaliação estrita. |
| 04 | Semi-Markov CRF | done | **Concluída.** DP própria validada por enumeração; treino e falhas estruturadas. |
| 05 | Validação cruzada aninhada | done | **Concluída.** 65 treinos, cinco folds externos, três internos e grade L2 fixa. |
| 06 | Candidatos não rotulados | ready-for-agent | **Funcional, status desatualizado.** Geração é exercitada pela matriz fatorial e pela suíte. |
| 07 | Relações por regras | ready-for-agent | **Funcional, status desatualizado.** Resultados e testes do baseline existem. |
| 08 | k-NN sobre candidatos previstos | ready-for-agent | **Funcional, status desatualizado.** Aplicação comum aos dois reconhecedores foi avaliada. |
| 09 | Matriz fatorial end-to-end | done | **Concluída.** Quatro braços + dois tetos, com atribuição de erros. |
| 10 | Knowledge Graph v2 | done | **Concluída.** Camadas de menção/conceito, JSONL canônico e exportações. |
| 11 | Orquestração pública | done | **Concluída em código.** O manifesto de desenvolvimento citado não está presente no workspace atual. |
| 12 | Teste externo congelado | in-progress | **Incompleta pelo protocolo original.** 63 elegíveis e 9 `CAUSES`; faltam revisões até o corte aplicável. |
| 13 | Avaliação externa final | provisional | **Executada como snapshot autorizado.** Não equivale ao teste externo definitivo pré-registrado. |

> **PROBLEMA DE CONSISTÊNCIA DO BOARD**
>
> As issues 06–08 aparecem abertas, mas a issue 09 está concluída e depende diretamente delas. A issue 01 também aparece aberta embora os contratos sejam usados em toda a cadeia. Recomenda-se atualizar status e checklists com links para commits, testes e manifestos; caso contrário, o estado do projeto fica contraditório.

### Evidência disponível e lacunas locais

- O pacote externo está presente: relatório, modelos congelados, snapshot, predições e manifesto.
- Os 18 hashes listados no manifesto externo foram recalculados nesta auditoria: **zero divergências**.

- Os diretórios de desenvolvimento citados nos documentos — `entity-nested-cv-v1`, `relation-factorial-v1`, `graph-v2` e `study-v1` — não estão presentes no workspace atual. Seus números são recuperáveis pela documentação versionada, mas os artefatos locais não puderam ser reverificados.
- O manifesto externo registra o commit `d4a46af…` com `dirty=true`. Os hashes protegem os arquivos, mas uma execução final de referência deve partir de árvore limpa e tag imutável.

# 4. Resultados de desenvolvimento

Os resultados nos cinco folds externos dos 42 documentos de desenvolvimento são exploratórios. Eles serviram para comparar braços e selecionar configurações sem reabrir o teste MCRC já consumido.

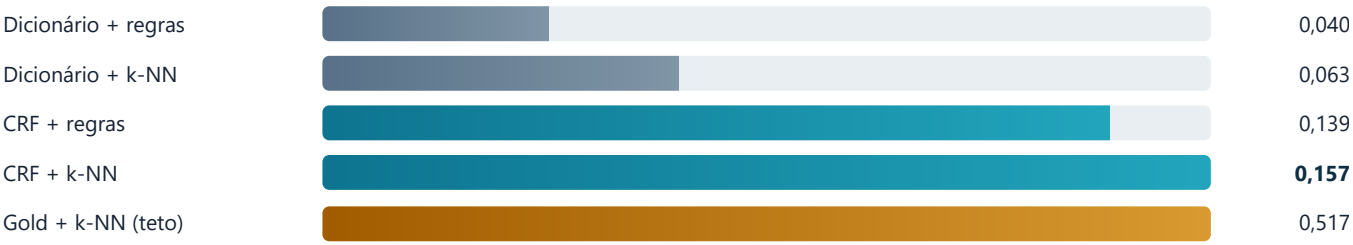
### Reconhecimento de entidades — macro-F1 estrita




Escala relativa ao melhor valor desta comparação. Médias ± desvio: dicionário 0,121 ± 0,013; CRF 0,285 ± 0,044.

| Métrica | Dicionário | CRF | Leitura |
|---|---|---|---|
| Macro-F1 estrita | 0,121 | **0,285** | CRF ≈ 2,4× melhor. |
| Micro-F1 | 0,149 | **0,243** | Ganho consistente no agregado. |
| Precisão micro | 0,108 | **0,343** | O contexto reduz fortemente entidades espúrias. |
| Revocação micro | **0,241** | 0,193 | CRF mais conservador. |
| Revocação de superfície OOV | 0,000 | **0,098** | Apenas o CRF generaliza além do léxico observado. |

### Relações end-to-end — macro-F1




Os quatro primeiros valores são end-to-end. O teto gold é diagnóstico e usa escala própria implícita; não deve ser apresentado como sistema operacional.

### Interpretação

- O CRF supera o dicionário com ambos os classificadores relacionais.
- O k-NN supera regras tanto no end-to-end quanto no teto com entidades gold.
- Entre 84% e 90% das relações gold perdidas em desenvolvimento são atribuídas a entidades ausentes ou incorretas.
- CAUSES é inconclusiva em três folds por suporte inferior a cinco.
- Nenhum dos cinco modelos finais do CRF convergiu em 250 iterações; 1 dos 60 treinos internos convergiu.

> **ACERTO CIENTÍFICO**
> A ausência de convergência não foi ocultada e nenhum braço foi removido por desempenho ruim. Isso preserva a comparação planejada e transforma falhas de otimização e propagação de erro em resultados observáveis.

## 5. Resultados externos provisórios

A execução externa usa 63 documentos elegíveis do MultiCaRe. Modelos e configurações foram congelados antes da leitura do gold. O resultado é válido como snapshot externo fornecido, mas não satisfaz a regra pré-registrada para uma conclusão definitiva.

| Braço | Papel | F1 macro entidades | F1 macro relações | F1 micro arestas KG |
|---|---|---|---|---|
| Dicionário + regras | End-to-end | 0,1373 | 0,0458 | 0,0578 |
| Dicionário + k-NN | End-to-end | 0,1373 | 0,0601 | 0,0724 |
| CRF + regras | End-to-end | **0,2415** | 0,1078 | 0,0941 |
| **CRF + k-NN** | End-to-end | **0,2415** | **0,1123** | **0,1153** |
| Gold + regras | Teto diagnóstico | — | 0,3265 | — |
| Gold + k-NN | Teto diagnóstico | — | 0,6053 | — |

### O que os números mostram

**MELHOR CONFIGURAÇÃO**

**CRF + k-NN** lidera os braços end-to-end nas relações e no grafo. A diferença para CRF + regras é pequena nas relações (0,1123 contra 0,1078), mas consistente com o desenvolvimento.

**GENERALIZAÇÃO**

O CRF externo reconheceu 930 menções para 2.832 gold. Sua precisão micro foi 0,405, mas a revocação foi 0,133. Em superfícies não vistas, a revocação caiu para 0,066.

**PROPAGAÇÃO DE ERRO**

No melhor braço, 2.244 de 2.340 falsos negativos relacionais — **95,9%** — são herdados de entidades não reconhecidas ou com borda/tipo incorretos.

**SUPORTE INSUFICIENTE**

`CAUSES` tem apenas 9 ocorrências externas, abaixo do mínimo 20, e é corretamente marcada como inconclusiva em todos os braços.

### Fragilidades específicas do NER externo

| Estrato/tipo no CRF | F1 | Implicação |
|---|---|---|
| `Condition` | 0,0486 | Quase não sustenta `HAS_CONDITION`. |
| `Finding` | 0,1669 | Classe majoritária ainda com baixa cobertura. |
| `Factor` | 0,3227 | Desempenho intermediário. |
| `Modifier` | 0,4278 | Melhor tipo, embora longe de robustez clínica. |
| Menções de 11–40 tokens | 0,0166 | Quase totalmente perdidas. |
| Superfícies não vistas | 0,1100 | Generalização lexical limitada. |

## Knowledge Graph

O melhor F1 micro de arestas conceituais foi 0,1153. A agregação conceitual recuperou duas arestas que não estavam corretas no nível estrito de menção. Esse ganho é útil para consumo do grafo, mas não corrige a evidência textual original; por isso a decisão de manter a métrica de menção/relação como primária está correta.

# 6. Decisões tomadas: avaliação crítica

| Decisão | Benefício | Custo ou risco | Parecer |
|---|---|---|---|
| Isolar o Project 2 do Project 1 | Evita regressões e mistura de protocolos. | Duplicação temporária e mais integração. | Acertada |
| Preservar corpus lossless e derivar gold plano | Não destrói sobreposições e proveniência. | Exige adjudicação e tratamento explícito de perdas. | Essencial |
| Semi-Markov CRF sem embeddings | Interpretável, alinhado ao objetivo metodológico. | Representação lexical fraca e baixa generalização. | Boa baseline |
| Manter dicionário independente | Baseline simples e transparente. | Muitos espúrios e zero recall de formas OOV. | Acertada |
| Mesmos classificadores entre reconhecedores | Permite atribuir ganho à etapa de entidades. | Não otimiza cada cadeia individualmente. | Acertada |
| JSONL v2 como fonte de verdade | Contrato auditável e sem limitação do CSV. | Maior complexidade de consumidores. | Acertada |
| Avaliar execução CRF não convergida | Evita viés de publicação e fallback oculto. | Métrica pode refletir otimização incompleta. | Acertada |
| Adjudicação gold por modelos | Viabilizou 233 casos e manteve trilha de votos. | Mesmo modelo nos papéis pode compartilhar erro sistemático. | Aceitável com ressalva |
| Parar revisão externa em 63 elegíveis | Permitiu obter sinal externo antecipado. | Quebra a regra de parada; `CAUSES` inconclusiva. | Somente provisório |
| Ordem lexical do teste externo | Determinística e auditável. | Não representa amostra aleatória do MultiCaRe. | Limitação declarada |

## Problemas de processo e reprodutibilidade

1. **Árvore Git suja no manifesto externo.** Os hashes permitem verificar a execução, porém o estado `dirty=true` dificulta reconstruir exatamente a versão do código apenas pelo commit.
2. **Artefatos de desenvolvimento ausentes no workspace.** A documentação preserva os resultados, mas não substitui os manifestos e saídas primárias para uma auditoria independente.
3. **Status de issues inconsistente.** O board não representa fielmente a implementação já exercitada pelos testes.
4. **Incompatibilidade de conversor durante a avaliação externa.** A primeira passagem revelou incompatibilidade com o gold adjudicado; a pontuação foi retomada com predições congeladas e hashes verificados. O procedimento é defensável, mas deve permanecer destacado.
5. **Perdas de projeção.** Oito menções externas cruzam fronteiras de sentença e não entram na métrica estrita; oito relações `HAS_FINDING` são registradas como perdas do grafo.

> **POR QUE O ESTUDO AINDA É VALIOSO**
>
> O baixo F1 não invalida o trabalho: o estudo responde onde a cadeia falha. Ele demonstra que o classificador relacional tem capacidade muito maior quando recebe endpoints corretos e quantifica objetivamente que o NER é o gargalo dominante.

## 7. Próximos passos priorizados

1. **Concluir o teste externo conforme o protocolo original.**
Continuar revisores B a partir do candidato 71 e C a partir do 76 até o candidato 110, remontar o prefixo elegível, aplicar a regra de parada e congelar antes de nova inferência. Meta: 100 documentos elegíveis ou 20 relações por classe; classes insuficientes devem permanecer inconclusivas.

2. **Estabilizar e diagnosticar a otimização do CRF.**
Investigar escala de features, regularização, tolerâncias, histórico do L-BFGS, normalização por sequência e curvas de objetivo/gradiente. Fazer ablações nos folds de desenvolvimento, sem tocar no snapshot externo.

3. **Atacar revocação de entidades, sobretudo `Condition`.**
Analisar os 1.613 casos ausentes em desenvolvimento e os 2.055 externos; separar ausência por comprimento, OOV, sentença e padrão morfológico. Adicionar features contextuais e lexicais permitidas como novo braço versionado, não como alteração silenciosa do baseline.

4. **Criar um braço moderno de comparação.**
Depois de preservar o baseline linear, avaliar encoder contextual biomédico ou modelo span-based com o mesmo gold, folds e contratos. O objetivo é medir o ganho de representação, não substituir retrospectivamente o CRF planejado.

5. **Melhorar relações somente após elevar o NER.**
O teto gold + k-NN de 0,6053 mostra espaço relacional, mas 95,9% dos falsos negativos do melhor braço externo são herdados de entidades. Priorizar o NER terá retorno maior que microajustes no classificador final.

6. **Revisar `CAUSES` e classes raras.**
Completar suporte externo; considerar amostragem de treino orientada a cobertura, análise de janela e um classificador específico por hipótese. Qualquer mudança deve ser escolhida apenas no desenvolvimento.

7. **Fortalecer o gold.**
Submeter uma amostra estratificada da projeção adjudicada por modelos a revisão humana, priorizando divergências, `Condition`, spans longos e casos de fronteira. Estimar taxa de erro sistemático antes de tratar `flat-gold-v1` como referência estável.

8. **Fechar a governança da entrega.**
Atualizar issues 01/06/07/08, registrar critérios cumpridos, publicar manifestos de desenvolvimento, criar tag de release com árvore limpa e reproduzir o manifesto raiz com `dirty=false`.

### Plano sugerido por horizonte

| Horizonte | Entregas | Critério de saída |
|---|---|---|
| Curto prazo | Corrigir status das issues; arquivar manifestos; tag limpa; completar revisão B/C. | Board coerente, teste externo congelável e artefatos verificáveis. |
| Próximo ciclo | Diagnóstico de convergência; ablação de features; análise focal de `Condition`, OOV e spans longos. | CRF convergente ou explicação experimental sustentada; ganho validado nos folds. |
| Médio prazo | Novo braço contextual/span-based; revisão humana amostral do gold. | Comparação justa sob contratos idênticos e estimativa de qualidade do gold. |
| Após congelamento | Uma única execução no teste externo definitivo. | Relatório final com suporte por classe, hashes e árvore limpa. |

## 8. Conclusão

O projeto entregou uma infraestrutura experimental substancialmente mais correta que a abordagem anterior baseada em entidades gold. A principal contribuição não é um F1 alto, mas a capacidade de executar, auditar e decompor o pipeline completo. O semi-Markov CRF superou o dicionário, e o k-NN superou as regras, tanto no desenvolvimento quanto no snapshot externo.

Os resultados também são claros sobre o limite atual: o sistema perde a maioria das relações porque não reconhece seus endpoints. O salto de macro-F1 relacional de 0,1123 no melhor end-to-end para 0,6053 com entidades gold confirma que o investimento imediato deve recair sobre entidades, não sobre a camada conceitual do grafo.

Em termos de maturidade, a implementação pode ser considerada **concluída como plataforma de pesquisa**. O estudo não deve ser chamado de validação externa definitiva enquanto a issue 12 permanecer incompleta. A próxima versão deve combinar três frentes: encerramento rigoroso do conjunto externo, melhoria sistemática do NER e consolidação da governança/reprodutibilidade.

> **RECOMENDAÇÃO FINAL**
>
> Não promover o pipeline para uso clínico. Publicar os números atuais como resultados exploratórios e externos provisórios; concluir a coleta pré-registrada; então avaliar uma versão congelada, sem ajustes posteriores, mantendo `CAUSES` inconclusiva caso o suporte continue insuficiente.

## Apêndice A — Fontes consultadas

- PRD: `.scratch/global-entity-recognition/spec.md`.
- Issues: `.scratch/global-entity-recognition/issues/01…13.md`.
- Decisões: `docs/adr/0001…0012`, `docs/external-final-scope-decision.md` e `annotations/entity-gold-v1/README.md`.
- Resultados: `docs/entity-recognizer-comparison.md`, `docs/relation-factorial-results.md`, `docs/knowledge-graph-v2.md`, `docs/external-final-evaluation.md` e `docs/ngram-knn-results.md`.
- Checkpoint externo: `docs/external-review-checkpoint.md`.
- Artefatos externos: `artifacts/external-final-evaluation-v1/report.json` e `manifest.json`.

## Apêndice B — Verificações desta auditoria

| Verificação | Resultado |
|---|---|
| Suíte completa com ambiente virtual do projeto | **210 passed** em 60,81 s |
| Hashes do manifesto da avaliação externa | **18 verificados; 0 divergências** |
| Status do manifesto externo | `completed` |
| Ambiente registrado | Python 3.14.6; PyTorch 2.14.1+cpu |
| Estado Git registrado | Commit `d4a46af…`; `dirty=true` |

Este relatório não reproduz texto clínico. Métricas e contagens foram extraídas dos relatórios e manifestos do projeto. O documento distingue resultados end-to-end, tetos diagnósticos e métricas secundárias do grafo.